



DEPARTAMENTO
DE COMPUTACION


Facultad de Ciencias Exactas y Naturales - UBA

Laboratorio de datos

Clasificación y métricas

Verano 2026


Recorrido de la materia (hasta ahora)



1º parte de la materia

- ✓ Lenguaje de programación (Python)
- ✓ Modelado conceptual de los datos (DER)
- ✓ Representación de los datos (modelo relacional)
- ✓ Formas de consultar los datos (AR/SQL)
- ✓ Recomendaciones para el diseño (Normalización)
- ✓ Calidad de datos
- ✓ Leyes acerca de la Protección de Datos

Recorrido de la materia (hasta ahora)




- ✓ Visualización y Exploración de los datos
- ✓ Introducción al Modelado
- ✓ Modelos de clasificación
- ✓ Selección de Modelos

2º parte de la materia

Aprendizaje supervisado

A partir de un modelo basado en algunos supuestos, se entrena un algoritmo de manera de construir las reglas a partir de la observación de datos etiquetados.



Clasificación

- A partir de los atributos (variables explicativas) queremos poder determinar la etiqueta - la **variable categórica Y**.
- Aprendizaje supervisado: contamos con un **conjunto de entrenamiento** en el cual conocemos las etiquetas - valores de la variable Y.
- Evaluación del modelo: **medida** relacionada con la cantidad de elementos bien o mal clasificados.

Clasificación

Tipos de clasificación

- Binaria - Dos clases, True/False, Positivo/Negativo
- Multiclase - Más de dos clases

K Nearest Neighbors (KNN)

Para determinar la clase de una nueva observación:


1. Buscar los puntos más cercanos, dentro del conjunto de entrenamiento
2. Ver qué clases tienen
3. Elegir la mayoritaria

¿Cuántos puntos consideramos? Depende del valor de k .


Si $k = 5$.

Buscamos los 5 más cercanos, entre los que ya tenemos etiquetados.

Tomamos la clase mayoritaria.



Árboles de decisión




El árbol representa una **disyunción de conjunciones sobre valores de atributos**.

En el ejemplo la fórmula quedaría:

$$(\text{Sex} == \text{Female}) \vee (\text{Age} < 5) \vee (\text{Age} \geq 5 \wedge \text{Pclass} == 1)$$

Ejemplo con Iris



¿Tenemos un clasificador bueno?

Medidas para evaluar clasificadores

Exactitud

La exactitud o *accuracy* que es una medida numérica que cuenta la proporción de observaciones *bien* clasificadas.

	0	1	2
0	50	0	0
1	0	29	21
2	0	0	50

$$50+29+50 = 129$$
$$129/150 = 0.86$$

Evaluación de modelos $\leftrightarrow$ **selección** de modelos

Necesitamos poder evaluar los modelos de una forma efectiva para:

- Comparar configuraciones de algoritmos
- Estimar la performance que tendrá el modelo “en la realidad”

Evaluar bien significa entender cómo será el uso, cuál es el objetivo del modelo, qué métrica refleja bien lo que queremos medir.

Ejemplo

Se trata de detectar una enfermedad. Se estima que la proporción de población enferma es del 6%.

Desarrollaron un test que tiene 94% de exactitud. ¿Es bueno?

Ejemplo

1% de las mujeres tienen cáncer de mama. Desarrollaron un test que tiene esta performance.

	Cancer (1%)	No Cancer (99%)
Test Pos	80%	9.6%
Test Neg	20%	90.4%

Es decir:

- 1% de los casos es positivo
- De los casos positivos, el 80% testea positivo.
- De los negativos, 9.6% testea positivo.

¿Cómo es la matriz de confusión?

$$\begin{pmatrix} 0.01 \cdot 0.8 & 0.99 \cdot 0.096 \\ 0.01 \cdot 0.2 & 0.99 \cdot 0.904 \end{pmatrix}$$

¿SUMA 100%?

Ejemplo


- ¿Cuánto es el accuracy?
- ¿Si el test da positivo, significa que el paciente tiene la enfermedad?

$$\begin{pmatrix} 0.01*0.8 & 0.99*0.096 \\ 0.01*0.2 & 0.99*0.904 \end{pmatrix}$$

Ejemplos

Métricas utilizadas:

- Accuracy
- Precision
- Recall
- F1 score
- ROC y AUC



Predicting user satisfaction from customer service chats

<https://publicaciones.sadio.org.ar/index.php/EJS/article/view/839/677>




Fig. 10. Distribución del Conjunto de Números.

Reuse of a Deep Learning model for handwritten digit recognition

<https://publicaciones.sadio.org.ar/index.php/EJS/article/view/841/679>




Fig. 4. Comparación de los dos enfoques utilizados

Técnicas de Deep Learning aplicadas a un sistema de clasificación de objetos para un recolector de residuos inteligente - <https://publicaciones.sadio.org.ar/index.php/EJS/article/view/844/681>

Medidas de performance

Matriz de confusión - caso binario

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

		True Class	
		Positive	Negative
Predicated Class	Positive	TP	FP
	Negative	FN	TN

ERA ASÍ O TRASPUESTA?

TP: true positives

FP: false positives

TN: true negatives


FN: false negatives

No dice nada sobre los tipos de aciertos y de errores que tiene el modelo.

Ej: autenticación en aplicación por voz.

- FP: autentica a un impostor
- FN: no autentica a un usuario válido

Tipos de error



Tomado de Towards Data Science

Medidas de performance

$$\text{Precisión} = \frac{TP}{TP + FP}$$

de las instancias clasificadas como positivas, cuántas lo son
(cuán útiles son los resultados de búsqueda)

$$\text{Recall} = \frac{TP}{TP + FN} \quad (\text{exhaustividad})$$

de las instancias positivas, cuántas fueron clasificadas como positivas
(cuán completos son los resultados)

Medidas de performance

$$\text{Recall} = \frac{TP}{TP + FN} \quad \text{Precisión} = \frac{TP}{TP + FP}$$

¿Cuál medida de performance debería priorizar cada uno de estos sistemas?

- enfermedad contagiosa
- test de embarazo
- filtro spam

Media armónica:

$$F\text{-measure} = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}$$

También llamada **F₁ score**.

Fórmula general:

$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{Precisión} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precisión}) + \text{Recall}}$$

F₂ da más peso a Recall

F_{0.5} da más peso a Precisión

Medidas de performance

$$\text{Recall} = \frac{TP}{TP + FN} = \text{Sensitivity o bien True Positive Rate}$$

$$\frac{TN}{TN + FP} = \text{Specificity o bien True Negative Rate}$$

Sensitivity/TPR: Porcentaje de pacientes **enfermos** correctamente diagnosticados.
Proporción de usuarios válidos autenticados

Specificity: Porcentaje de pacientes **sanos** correctamente diagnosticados.

$$\text{FPR} = \frac{FP}{FP + TN}$$

Ej. FPR: Proporción de impostores que aceptamos erróneamente.

$$\text{Precisión} = \text{PPV} = \frac{TP}{TP + FP}$$

¿Qué hacemos con un resultado de un estudio médico que nos da mal, pero que tiene bajo PPV?

Ejercicio

En los ejemplos vistos, comparar los clasificadores con las distintas métricas.

- Accuracy (Exactitud)
- Precision
- Recall
- F1

Casos multiclase

	Manzana (predicho)	Naranja (predicho)	Oliva (predicho)	Pera (predicho)
Manzana (real)	MM	MN	MO	MP
Naranja (real)	NM	NN	NO	NP
Oliva (real)	OM	ON	OO	OP
Pera (real)	PM	PN	PO	PP

Las medidas **precisión, recall, etc.** sólo pueden formularse en forma binaria: **cada clase contra el**

$$\text{Precisión}(\text{Manzana}) = \frac{MM}{MM + NM + OM + PM}$$

$$\text{Recall}(\text{Manzana}) = \frac{MM}{MM + MN + MO + MP}$$

Bibliografía

Libros:

- Introduction to Machine Learning with Python, Müller & Guido
- Machine Learning - Mitchell

